

Diego Hernandez Rodriguez
@eu_sou_dieguito
C311

Esta tarea representa un análisis del modelo $f(x, y) = (x^2 + 1)^{(y^2+1)} + e^y + e^{-y}$ mediante el uso de los algoritmos, aprendidos en las conferencias de Algoritmos para problemas Irrestritos y con restricciones, de Máximo Descenso y de Newton.

1 Problema a analizar

El problema a analizar es la ecuación:

$$f(x, y) = (x^2 + 1)^{(y^2+1)} + e^y + e^{-y}$$

Su dominio son los reales ya que no tiene punto de indefinición y es continua en todo su dominio por composición de funciones continuas elementales.

Esta representa la siguiente función en 3D:

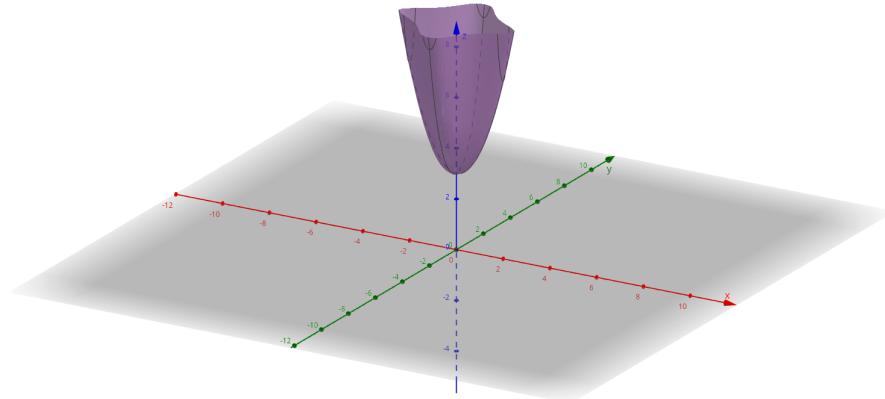


Figura que muestra la continuidad de dicha función.

2 Análisis del modelo, soluciones y convexidad

Analizando el problema mas a profundidad, aqui vemos las derivadas parciales de la función:

$$\frac{\partial f}{\partial x} = 2x(y^2 + 1)(x^2 + 1)^{y^2}$$

$$\frac{\partial f}{\partial y} = 2y \ln(x^2 + 1)(x^2 + 1)^{(y^2+1)} + e^y - e^{-y}$$

Sus segundas derivadas parciales:

$$\frac{\partial^2 f}{\partial x^2} = (y^2 + 1)(2(x^2 + 1)^{y^2} + (2xy)^2(x^2 + 1)^{(y^2-1)})$$

$$\frac{\partial^2 f}{\partial y^2} = 2 \ln(x^2 + 1)(x^2 + 1)^{(y^2+1)}(1 + 2y^2 \ln(x^2 + 1)) + e^y + e^{-y}$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x} = 4xy(x^2 + 1)^{y^2}(1 + (y^2 + 1) \ln(x^2 + 1))$$

Y dadas las segundas derivadas no creo que sea necesario representar la matriz Hessiana.

Dicha función es continua y estrictamente positiva en todo su dominio.

Ahora para ver la existencia de sus mínimos locales vamos a analizar sus derivadas parciales para ver cuando el vector gradiente se hace igual al (0,0).

$\frac{\partial f}{\partial x} = 0$ si y solo si $x = 0$, puesto que $(y^2 + 1) > 0$ para todo y , $(x^2 + 1) > 0$ para todo x y $(x^2 + 1)^{(y^2)} > 0$ para todo x , por tanto $2x$ debe ser igual a 0, por tanto $x = 0$.

Ahora viendo $\frac{\partial f}{\partial y} = 0$ con $x = 0$, tenemos que $\ln(x^2 + 1) = \ln(1) = 0$, por ende $e^y - e^{-y}$ tiene que ser igual a 0, osea $y = -y$, lo que implica que y también es igual a 0, el punto $P(0,0)$ es un mínimo local.

Ahora analizando las derivadas parciales de segundo orden podemos ver que:

$$(x^2 + 1)^{(y^2)} > 0 \text{ para todo } x, y$$

$$y^2(x^2 + 1)^{(y^2-1)} > 0 \text{ para todo } x, y$$

$$(y^2 + 1) > 0 \text{ para todo } y$$

$$(2x)^2 > 0 \text{ para todo } x$$

$$\text{por tanto } \frac{\partial^2 f}{\partial x^2} > 0 \text{ para todo } x, y$$

$\ln(x^2 + 1) > 0$ para todo x

$(x^2 + 1)^{(y^2+1)} > 0$ para todo x, y

$\ln(x^2 + 1)y^2 > 0$ para todo x, y

$e^y + e^y > 0$ para todo y

Por tanto $\frac{\partial^2 f}{\partial y^2} > 0$ para todo x, y

Para el analisis de convexidad de la funcion use las librerias de sympy y numpy

de python, las cuales tienen metodo de calculo de la matriz hessiana y en dependencia de esta empieza a ver convexidad en todos los puntos en un rango especifico, lo cual determino no convexidad en numerosos puntos, para verificar se puede compilar el archivo `checkConvexity.py` y ver los resultados.

3 Descripcion de los algoritmos

Los metodos utilizados son el de Newton y el de Maximo descenso:

El metodo de Maximo descenso es un algoritmo iterativo que busca el minimo siguiendo la direccion opuesta del vector gradiente, el maximo descenso de la funcion, consiste en comenzar con un punto x_0 y luego para cada k iteracion $x_{(k+1)} = x_k - a_k df(x_k)$. Este algoritmo es facil de implementar pero tiene una convergencia relativamente lenta, dada la cantidad de iteraciones necesarias.

El Metodo de Newton en cambio usa informacion de las derivadas de segundo orden, de la matriz Hessiana, aproximando la funcion localmente por una cuadratica, comienza en un punto x_0 inicial y luego en cada iteracion $x_{(k+1)} = x_k - (d^2 f(x_k))^{-1} df(x_k)$, dadas sus caracteristicas tiene una convergencia muy rapida pero es bastante complicada de implementar.

En el config.json se puede encontrar un conjunto de puntos los cuales estan seleccionados de la siguiente forma:

- El punto 1 es un punto cercano al minimo
- Los puntos del 2 al 4 son puntos lejos del minimo
- Los 5 y 6 se encuentran en los ejes
- Los 7 y 8 son puntos cerca de puntos potenciales criticos

Dicho esto y aplicados los algoritmos en estos puntos se evidencia que los puntos cercanos al minimo tienen una convergencia rapida como esperado, los mas alejados del minimo se tomaron para una prueba de robustez la cual fue demostrada con ambos metodos, aunque en ambos puntos el metodo de Newton converge mucho mas rapido que el de maximo descenso. Los puntos de los ejes tienen una peculiaridad, ya que el punto 5 converge, este entra dentro de los puntos cercanos al minimo, pero el punto 6 al tener la $x = 0$ tiene un comportamiento catastrofico y no converge. Con los puntos 7 y 8 ambos metodos convergen bien, pero en 7 newton es mas rapido pero menos preciso y en 8 maximo descenso es mas estable.




Figure 1: Trayectorias

4 Conclusiones

Los resultados de dichos algoritmos pueden verse con el código que puedes encontrar en el https://github.com/IamSkale/tarea_M0 donde en el config.json puedes modificar los puntos que quieras verificar y obtener resultados distintos a los mostrados en este informe.

A modo de resumen pudimos ver con este código que el método de Newton tiene una convergencia a resultados en mucha menor cantidad de iteraciones que el método de maximo descenso, pero a su vez es mas difícil de implementar y de entender lo cual lo hace menos escalable.




Figure 2: Convergencia de los métodos