Diego Hernandez Rodriguez
@eu_sou_dieguinho
C311

Esta tarea representa un analisis del modelo $f(x,y) = (x^2+1)^{(y^2+1)} + e^y + e^{-y}$ mediante el uso de los algoritmos, aprendidos en las conferencias de Algoritmos para problemas Irrestrictos y con restricciones, de Maximo Descenso y de Newton.

1 Problema a analizar

El problema a analizar es la ecuacion:

$$f(x,y) = (x^2+1)^{(y^2+1)} + e^y + e^{-y}$$

Su dominio son los reales ya que no tiene punto de indefinicion y es continua en todo su dominio por composicion de funciones continuas elementales.
Esta representa la siguiente funcion en 3D:

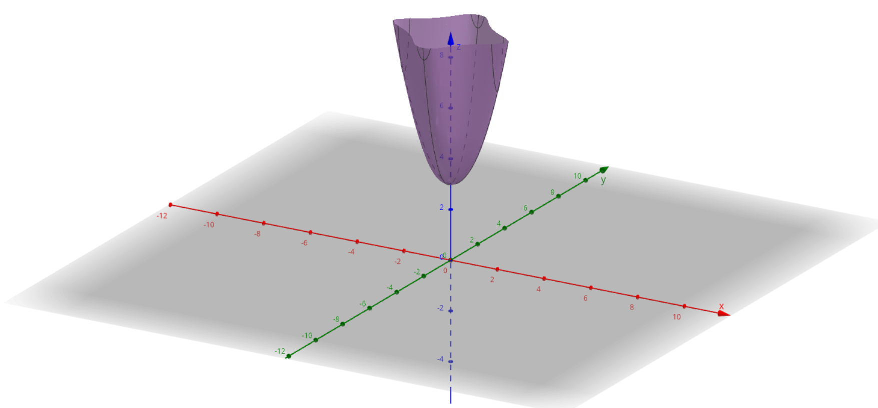

Figura que muestra la continuidad de dicha funcion.

2 Analisis del modelo, soluciones y convexidad

Analizando el problema mas a profundidad, aqui vemos las derivadas parciales de la funcion:

$$\frac{\partial f}{\partial x} = 2x(y^2+1)(x^2+1)^{y^2}$$

$$\frac{\partial f}{\partial y} = 2y\ln(x^2+1)(x^2+1)^{(y^2+1)} + e^y - e^{-y}$$

Sus segundas derivadas parciales:

$$\frac{\partial^2 f}{\partial x^2} = (y^2+1)(2(x^2+1)^{y^2} + (2xy)^2(x^2+1)^{(y^2-1)})$$

$$\frac{\partial^2 f}{\partial y^2} = 2\ln(x^2+1)(x^2+1)^{(y^2+1)}(1+2y^2\ln(x^2+1)) + e^y + e^{-y}$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x} = 4xy(x^2+1)^{y^2}(1+(y^2+1)\ln(x^2+1))$$

Y dadas las segundas derivadas no creo que sea necesario representar la matriz Hessiana.

Dicha funcion es continua y estrictamente positiva en todo su dominio.
Ahora para ver la existencia de sus minimos locales vamos a analizar sus derivadas parciales para ver cuando el vector gradiente se hace igual al (0,0).

$\frac{\partial f}{\partial x} = 0$ si y solo si $x = 0$, puesto que $(y^2+1) > 0$ para todo y, $(x^2+1) > 0$ para todo x y $(x^2+1)^{(y^2)} > 0$ para todo x, por tanto $2x$ debe ser igual a 0, por tanto $x = 0$.
Ahora viendo $\frac{\partial f}{\partial y} = 0$ con $x = 0$, tenemos que $\ln(x^2+1) = \ln(1) = 0$, por ende $e^y - e^- y$ tiene que ser igual a 0, osea $y = -y$, lo que implica que y tambien es igual a 0, el punto $P(0,0)$ es un minimo local.
Ahora analizando las derivadas parciales de segundo orden podemos ver que:

$(x^2+1)^{(y^2)} > 0$ para todo x, y

$y^2(x^2+1)^{(y^2-1)} > 0$ para todo x, y

$(y^2+1) > 0$ para todo y

$(2x)^2 > 0$ para todo x

por tanto $\frac{\partial^2 f}{\partial x^2} > 0$ para todo x, y

$\ln(x^2+1) > 0$ para todo x

$(x^2+1)^{(y^2+1)} > 0$ para todo x, y

$\ln(x^2+1)y^2 > 0$ para todo x, y

$e^y + e^y > 0$ para todo y

Por tanto $\frac{\partial^2 f}{\partial y^2} > 0$ para todo x, y

Luego de mucho analisis y extensos calculos tambien llegamos a que el determinante de la matriz Hessiana es > 0, ya que $\frac{\partial^2 f}{\partial x^2} > 0$, $\frac{\partial^2 f}{\partial y^2} > 0$ y $\frac{\partial^2 f}{\partial y^2} \cdot \frac{\partial^2 f}{\partial y^2} > \frac{\partial^2 f}{\partial x \partial y} > 0$ por tanto la funcion es estrictamente convexa, por lo cual el punto (0,0) es minimo global.

3 Descripcion de los algoritmos

Los metodos utilizados son el de Newton y el de Maximo descenso:

El metodo de Maximo descenso es un algoritmo iterativo que busca el minimo

siguiendo la direccion opuesta del vector gradiente, el maximo descenso de la funcion, consiste en comenzar con un punto x_0 y luego para cada k iteracion $x_{(k+1)} = x_k - a_k df(x_k)$. Este algoritmo es facil de implementar pero tiene una convergencia relativamente lenta, dada la cantidad de iteraciones necesarias.

El Metodo de Newton en cambio usa informacion de las derivadas de se-

gundo orden, de la matriz Hessiana, aproximando la funcion localmente por una cuadratica, comienza en un punto x_0 inicial y luego en cada iteracion $x_{(k+1)} = x_k - (d^2 f(x_k))^{-1} df(x_k)$, dadas sus caracteristicas tiene una convergencia muy rapida pero es bastante complicada de implementar.

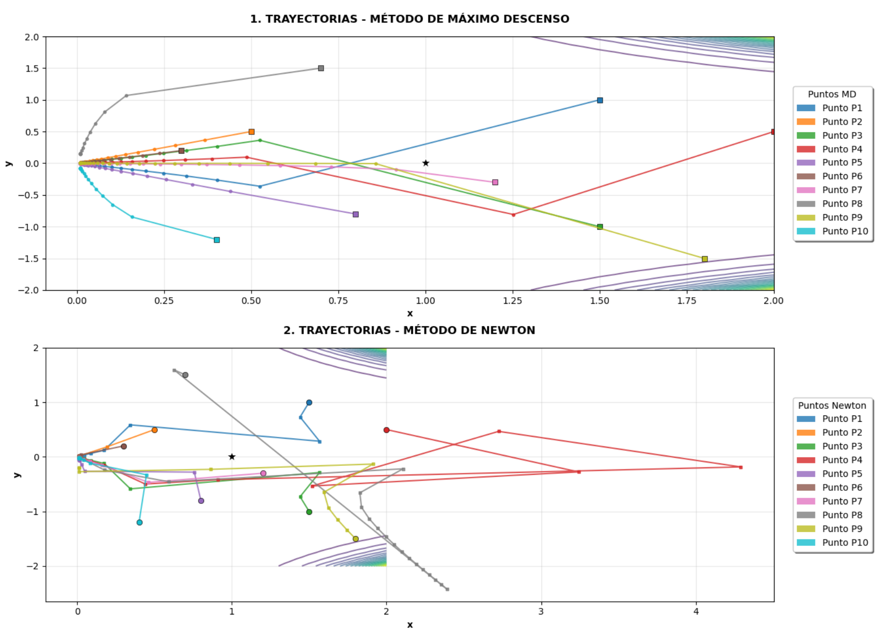

Figure 1: Trayectorias

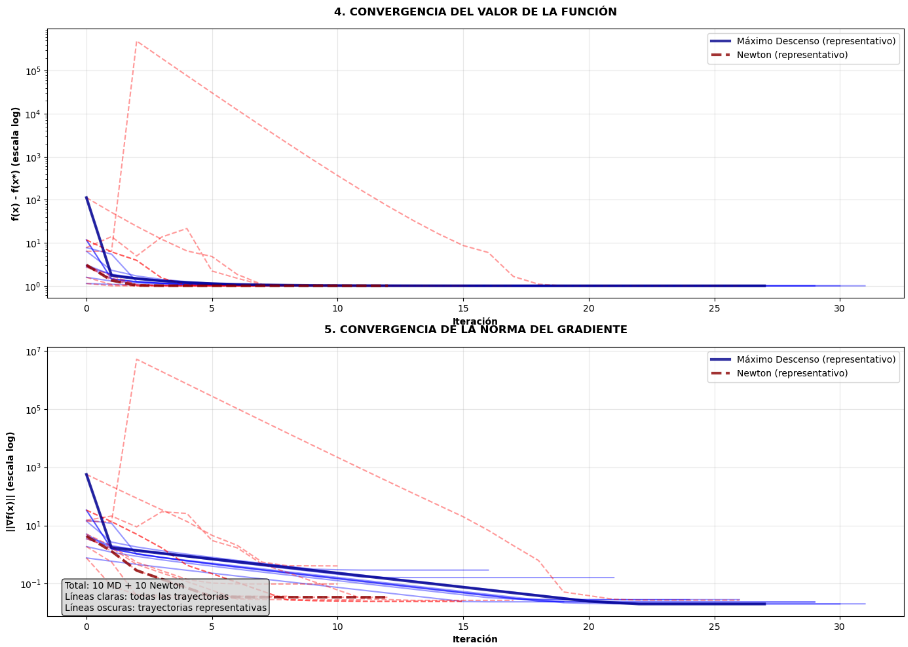

Figure 2: Convergencia de los metodos

4 Conclusiones

Los resultados de dichos algoritmos pueden verse con el codigo que puedes encontrar en el `https://github.com/IamSkale/tarea_MO` donde en el config.json puedes modificar los puntos que quieras verificar y obtener resultados distintos a los mostrados en este informe.

A modo de resumen pudimos ver con este codigo que el metodo de Newton tiene una convergencia a resultados en mucha menor cantidad de iteraciones que el metodo de maximo descenso, pero a su vez es mas dificil de implementar y de entender lo cual lo hace menos escalable.